

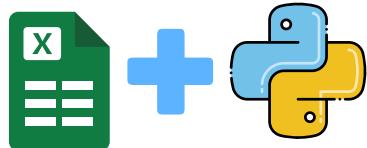


Diego Santiago Vieira de Brito

indicium



ANÁLISE DE DADOS / ENGENHARIA DE ANALYTICS



+55(65)99972-1540

<https://github.com/DiegoSVBrito/DiegoSVBrito>

Resumo da abordagem do projeto – Desafio Indicium- LightHouse

Desde o início, fiquei muito entusiasmado, quando vi o post no LinkedIn sobre o desafio da Light-House Indicium.

Uma oportunidade singular de aplicar e aprimorar minhas habilidades em um desafio prático. Comecei dedicando meus esforços ao desafio de Engenharia de Dados, enfrentando alguns obstáculos técnicos ao longo do caminho. No entanto, após uma análise estratégica, decidi migrar para o desafio de Análise de Dados, uma área em que possuo maior experiência e conforto.

Mergulhei no estudo minucioso do enunciado e das planilhas fornecidas, buscando compreender cada detalhe. Dediquei-me à modelagem dos relacionamentos entre as tabelas, identificando chaves primárias e estrangeiras. Optei pelo esquema Snowflake devido à presença de tabelas de relacionamento, o que se mostrou a escolha mais adequada. Realizei uma classificação cuidadosa dos dados no Excell, garantindo tipos corretos para cada coluna, e executei a limpeza e padronização necessárias para viabilizar as análises posteriores.

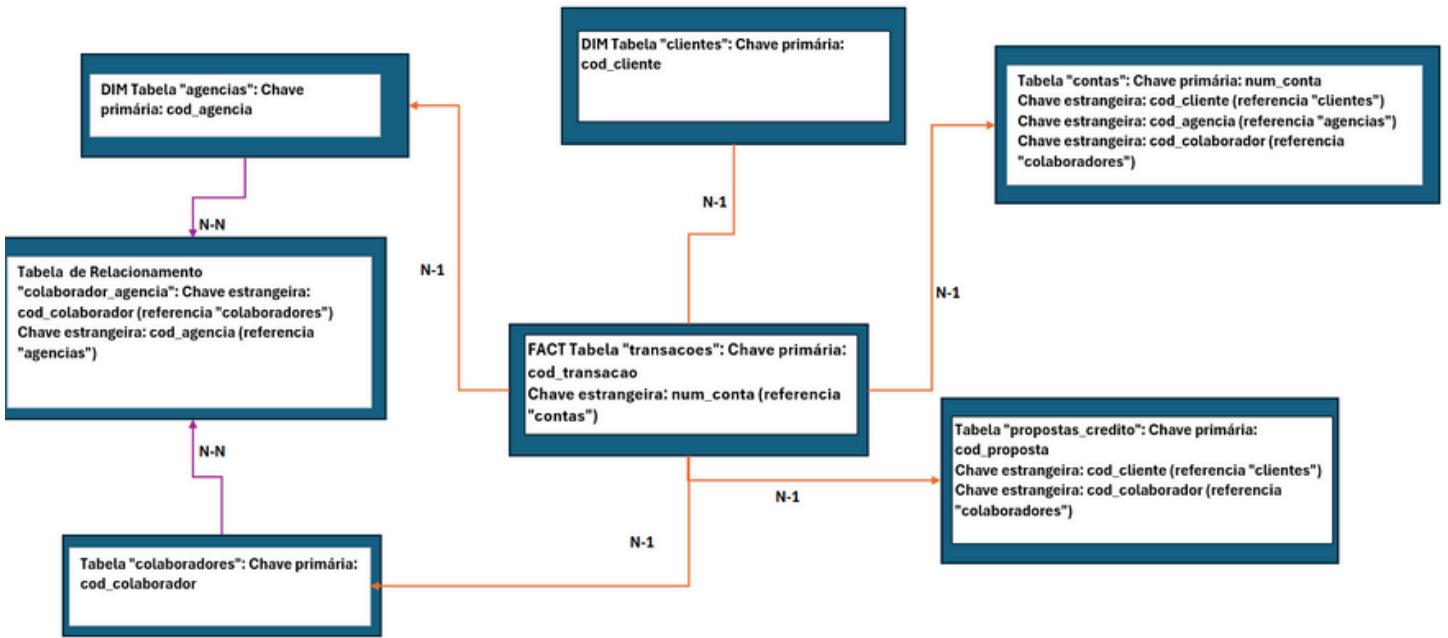
Quando se tratou de escolher as ferramentas, não tive dúvidas em optar pelo Python como minha linguagem de programação principal para a análise dos dados. Minha familiaridade, combinada com a versatilidade e o poder do Python na manipulação e exploração de datasets, tornou essa escolha natural para mim.

Utilizei bibliotecas especializadas em análise de dados, como Pandas, NumPy e Matplotlib, para facilitar o processo. Decidi estrategicamente usar Python em vez de ferramentas como Power BI, pois queria ter a flexibilidade de criar análises personalizadas e escaláveis, em vez de me limitar a um relatório estático.

Meu objetivo é realizar uma exploração aprofundada dos dados, buscando gerar insights relevantes para o negócio. Estou empenhado em criar visualizações impactantes que comuniquem os resultados de forma clara e convincente. Para isso, estou me dedicando a compreender as necessidades e "dores" específicas do negócio, elaborando perguntas estratégicas e definindo abordagens eficazes para respondê-las.

Em resumo, este projeto tem sido uma jornada de dedicação, estratégia e aprendizado contínuo. Desde a escolha do desafio até o estudo aprofundado dos dados, passando pela modelagem de relacionamentos, limpeza e padronização, cada etapa tem sido enriquecedora. Minha preferência pelo Python como ferramenta de análise se baseia na sua flexibilidade, poder e capacidade de criar análises personalizadas e escaláveis.

O entusiasmo que tenho pela área de análise de dados e o reconhecimento dos seus potenciais impactos positivos têm sido meus principais motivadores ao longo deste projeto. Estou ansioso para os próximos passos, nos quais me dedicarei a explorar os dados em profundidade, gerar insights relevantes e criar visualizações impactantes para atender às necessidades específicas do negócio.



Planejamento

Importação de lib

Leitura do Dataset

Explorando dataset

Criando Dicionário de Datasets

Exibindo formatos e dimensões dos dados

```
In [1]: # Indicium Light House- desafio Análise de Dados
## Procederemos a análise de dados, utilizando os arquivos CSV disponibilizados
## Faremos de modo didático e gradual, utilizando o notebook que ficará disponível posteriormente no github
## Buscaremos abordar os dados de modo a responder as perguntas e endereçar os KPIs

In [2]: ### Iniciamos importando as Libs necessárias para o desafio
import pandas as pd # manipulação de dados
import numpy as np # operações numéricas
import matplotlib.pyplot as plt # cria algumas visualizações
import seaborn as sns # gerar gráficos mais complexos
from datetime import datetime # manipulação de datas

In [3]: ## próximo passo é carregar os dados que serão utilizados, após feito o upload para o jupyter
## Carregamento dos datasets
caminho_dados = "Indicium_light_house/"

# Carregar cada dataset em um DataFrame
df_agencias = pd.read_csv(caminho_dados + "agencias.csv")
df_clientes = pd.read_csv(caminho_dados + "clientes.csv")
df_colab_agencia = pd.read_csv(caminho_dados + "colaborador_agencia.csv")
df_colaboradores = pd.read_csv(caminho_dados + "colaboradores.csv")
df_contas = pd.read_csv(caminho_dados + "contas.csv")
df_propostas = pd.read_csv(caminho_dados + "propostas_credito.csv")
df_transacoes = pd.read_csv(caminho_dados + "transacoes.csv")

In [40]: # agora precisamos realizar a primeira análise dos dados, visual e também quanto a dimensão dos dados
# Verificando as primeiras 15 linhas de cada dataset
print(df_transacoes.head(15))
print(df_propostas.head(15))
print(df_contas.head(15))
```

```
print("\nInformações sobre os datasets carregados:")
dfs = {
    "Agências": df_agencias,
    "Clientes": df_clientes,
    "Colaboradores Agência": df_colab_agencia,
    "Colaboradores": df_colaboradores,
    "Contas": df_contas,
    "Propostas Crédito": df_propostas,
    "Transações": df_transacoes,
}
# Exibir as primeiras informações descritivas de cada dataset
for nome, df in dfs.items():
    print(f"\n{nome} - Linhas: {df.shape[0]}, Colunas: {df.shape[1]}")
    print(df.head()) # Exibir as primeiras linhas do dataset
    print("\nInfo descritivas:")
    print(df.info())
```

Procedimentos

Convertendo colunas para Datetime

Agrupando em trimestres

Agregando colunas

Criando função para % de propostas

Visulização de resultados

Explanando KPIs

Criando indices

Visulização de resultados

```
In [5]: # Vamos a primeira pergunta:  
## Qual trimestre tem, em média, mais transações aprovadas e qual tem, também em média, maior volume movimentado?  
### Para responder a essa pergunta, precisamos seguir os seguintes passos:  
### Transformar os dados das colunas de data em formato datetime para melhor manipular  
### Criar uma coluna de trimestre na tabela de transações  
### Agrupar as transações por trimestre  
  
In [6]: # Convertendo a coluna de data para o tipo datetime  
df_transacoes['data_transacao'] = pd.to_datetime(df_transacoes['data_transacao'])  
  
# Criando a coluna de trimestre  
df_transacoes['trimestre'] = df_transacoes['data_transacao'].dt.quarter  
  
In [7]: # Agrupando as transações por trimestre e calculando a média usando o método groupby e .agg()  
transacoes_por_trimestre = df_transacoes.groupby('trimestre').agg(  
    media_transacoes=('cod_transacao', 'count'),  
    volume_medio='valor_transacao', 'sum')  
).reset_index()  
  
# Encontrando os trimestres com os maiores valores  
trimestre_mais_transacoes = transacoes_por_trimestre.loc[transacoes_por_trimestre['media_transacoes'].idxmax(), 'trimestre']  
trimestre_maior_volume = transacoes_por_trimestre.loc[transacoes_por_trimestre['volume_medio'].idxmax(), 'trimestre']  
  
print(f'O trimestre com mais transações em média é o {trimestre_mais_transacoes}º trimestre.')  
print(f'O trimestre com maior volume movimentado em média é o {trimestre_maior_volume}º trimestre.')  
  
O trimestre com mais transações em média é o 4º trimestre.  
O trimestre com maior volume movimentado em média é o 4º trimestre.  
  
In [8]: # o quarto trimestre apresenta maior volume e mais transações, o que implica não só que são realizados mais negócios  
# como também que os negócios tendem a ser mais substanciais, ou seja, as pessoas precisam de mais dinheiro no final do ano
```

```
In [10]: # Sabendo que o 4 trimestre tende a ser mais movimentado e volumoso, podemos responder sobre a taxa de aprovação  
# podemos chegar ao seguinte, numero absoluto de propostas que se realizaram em forma de negocio / valor total de propostas  
# podemos usar função lambda para encontrar os valores de Aprovada e somar estes valores inserindo o resultado em uma variável  
# na tabela de propostas existe o status da proposta que apresenta valores como: em análise, aprovada..  
# Contar o total de propostas e aprovações por trimestre  
  
# Converter a coluna de data para o tipo datetime no DataFrame df_propostas  
df_propostas['data_entra_proposta'] = pd.to_datetime(df_propostas['data_entra_proposta'])  
  
# Criar a coluna de trimestre no DataFrame df_propostas  
df_propostas['trimestre'] = df_propostas['data_entra_proposta'].dt.quarter  
  
# Contar o total de propostas e as aprovações por trimestre  
propostas_por_trimestre = df_propostas.groupby('trimestre').agg(  
    total_propostas=('cod_proposta', 'count'),  
    propostas_aprovadas='status_proposta', lambda x: (x == 'Aprovada').sum())  
).reset_index()  
  
# Calcular a taxa de aprovação por trimestre  
propostas_por_trimestre['taxa_aprovacao'] = (propostas_por_trimestre['propostas_aprovadas'] / propostas_por_trimestre['total_propostas'])  
  
# Combinar com as transações para analisar a relação entre aprovações e transações  
df_trimestre = transacoes_por_trimestre.merge(propostas_por_trimestre, on='trimestre', how='left')  
  
# Mostrar o trimestre com a maior taxa de aprovação  
df_trimestre_sorted = df_trimestre.sort_values(by='taxa_aprovacao', ascending=False)  
trimestre_maior_aprovacao = df_trimestre_sorted.iloc[0]  
  
print("\nTrimestre com maior taxa de aprovação:")  
print(f"Trimestre: {int(trimestre_maior_aprovacao['trimestre'])}")  
print(f"Média de transações: {(trimestre_maior_aprovacao['media_transacoes']):.0f}")  
print(f"Volume médio movimentado: R$ {(trimestre_maior_aprovacao['volume_medio']):,.2f}")  
print(f"Total de propostas: {int(trimestre_maior_aprovacao['total_propostas'])}")  
print(f"Propostas aprovadas: {int(trimestre_maior_aprovacao['propostas_aprovadas'])}")  
print(f"Taxa de aprovação: {(trimestre_maior_aprovacao['taxa_aprovacao']):.2f}%")
```

```
[1]: #vamos demonstrar alguns KPIs - Key Performance Indicators que podem ser úteis ao tomador de decisões  
# Taxa de aprovação de crédito - o coração do negócio- pode indicar melhores oportunidades de vender o produto  
# volume de transações por agência, possível integrar os dados de agências e de negócios realizados, encontrando qual  
# unidade vende mais e a partir daí tentar replicar os procedimentos as demais agências aumentando o aproveitamento  
# no mesmo sentido, quais os funcionários vendem mais, ou seja, quais profissionais podem ser os diretores ou gerentes  
# no propósito de que liderem times e campanhas para melhorar os índices e treinar mais colaboradores.
```

```
[11]: # 1. Taxa de Aprovação de Crédito  
df_propostas['aprovada'] = df_propostas['status_proposta'].apply(lambda x: 1 if x == 'Aprovada' else 0)  
taxa_aprovacao = df_propostas['aprovada'].mean() * 100  
print(f'Taxa de Aprovação de Crédito: {taxa_aprovacao:.2f}%')
```

```
Taxa de Aprovação de Crédito: 25.70%  
  
[59]: # 2. Volume de Transações por Agência  
transacoes_por_agencia = df_transacoes.groupby('num_conta').agg(  
    total_transacoes='valor_transacao', 'count',  
    volume_total='valor_transacao', 'sum')  
).reset_index()  
  
df_contas_agencias = df_contas[['num_conta', 'cod_agencia']].merge(transacoes_por_agencia, on='num_conta', how='left')  
df_agencias_transacoes = df_contas_agencias.merge(df_agencias[['cod_agencia', 'nome', 'cidade']], on='cod_agencia', how='left')  
agencias_transacoes = df_agencias_transacoes.groupby(['nome', 'cidade']).agg(  
    total_transacoes='total_transacoes', 'sum',  
    volume_total='volume_total', 'sum')  
).reset_index()  
  
print("Top 10 Agências com Maior Volume de Transações:")  
print(agencias_transacoes.sort_values(by='volume_total', ascending=False).head(10))  
  
Top 10 Agências com Maior Volume de Transações:
```



À Senhora:
Sofia Oliveira - CEO

RELATÓRIO TRIMESTRAL DE ANÁLISE DE DADOS

Responsável: Diego Santiago Vieira de Brito –
SADI (setor de análise de dados e inovação)

+55(65)99972-1540

Estimada Senhora Sofia Oliveira,

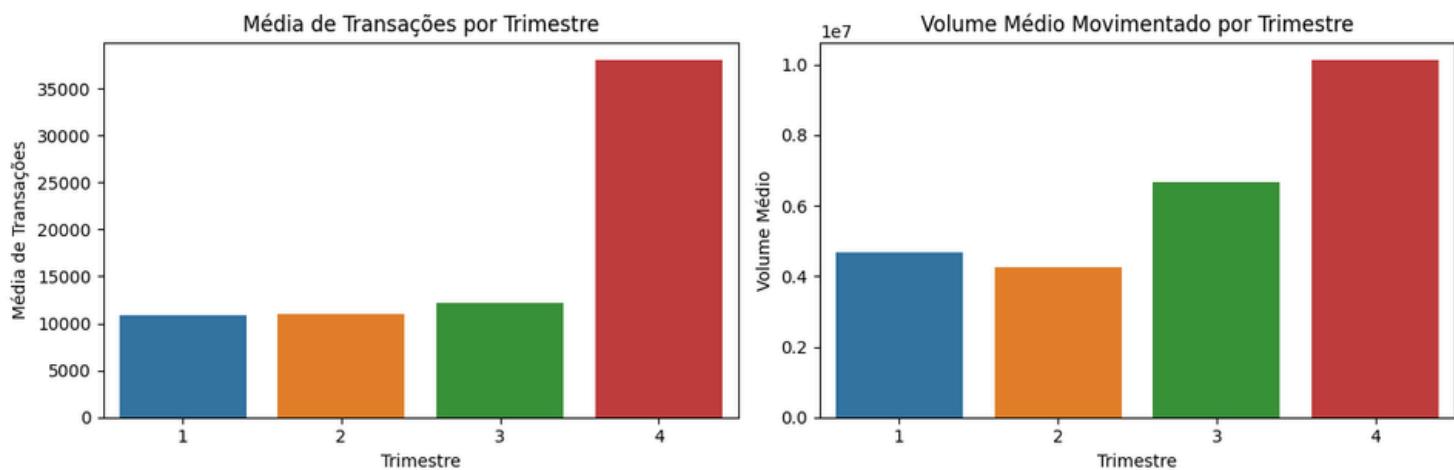
Cumprimentando-a, cordialmente, aproveito do ensejo para encaminhar aos cuidados e apreciação da presidência do BanVic o relatório encomendado conforme reunião pretérita da equipe, ademais, tomei a liberdade de adicionar algumas ações que são arrimadas em *insights* quando da análise exploratória dos dados.

Respondendo às primeiras perguntas:

O trimestre com mais transações em média é o 4º trimestre.

O trimestre com maior volume movimentado em média é o 4º trimestre.

Após análise trimestral das séries temporais, ficou claro que o último trimestre doa no apresenta maior volume de operações, ademais as operações são de maior monta, conforme demonstram os gráficos de barra abaixo.



Insights:

Como demonstrado pela análise: há uma busca por crédito que se intensifica no nos meses de outubro a dezembro, tanto sob o aspecto de números absolutos(quantidade de pedidos de crédito) quanto ao valor solicitado.

Ações:

Neste sentido, seria mais estratégico que as campanhas de marketing podem ser melhor direcionadas se realizadas nos meses anteriores, para que o efeito seja potencializado no final do ano.

De mesmo modo, os procedimentos de RH, em especial contratação de e demissão, devem ser realizados, preferencialmente, no primeiro ou segundo trimestre, visto que seleção e desligamento de colaboradores tendem a levar tempo. Ademais, visto que a demanda cresce no último quartil é essencial que as equipes não estejam desfalcadas.

Respondendo ao próximo questionamento:

O Trimestre com maior taxa de aprovação: é o terceiro

Média de transações: 12190

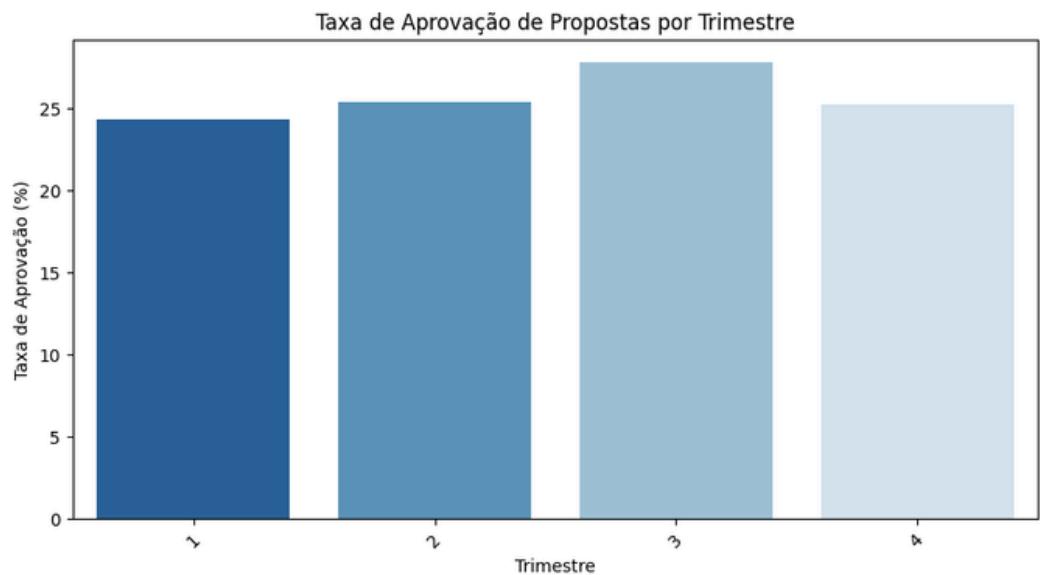
Volume médio movimentado: R\$ 6,654,486.96

Total de propostas: 522

Propostas aprovadas: 145

Taxa de aprovação: 27.78%

Após análise dos volumes de negócios e das aprovações resultantes



Insights:

Como demonstrado pela análise: há uma busca por crédito que se intensifica nos meses de outubro a dezembro, contudo o maior índice de aprovação é no terceiro trimestre. Há algo a ser corrigido aqui, que seria melhorar a gestão de aprovação de crédito.

Como há uma demanda maior por crédito no final do ano, e há um volume maior de contratações e de valores contratados, agregando este fato ao de que o maior percentual de aprovação é no terceiro trimestre, isso implica que o banco está perdendo um grande volume de negócios no último trimestre.

Ações:

O banco deve reavaliar sua política e critérios de aprovação, possivelmente aumentar o número de colaboradores no último trimestre para dar melhor resposta ao crescimento no volume de negócios.

Outra forma de atender ao crescimento de demanda seria criar ferramentas de avaliação e aprovação de crédito, em especial de menor monta, por vias digitais.

Ademais, visto que a demanda cresce no último quartil é essencial que as equipes tenham em mente que a demanda muda e traçarem estratégias a partir deste fato.

Respondendo ao Próximo questionamento:

O colaborador André Tech levantou a possibilidade e implicações sobre o uso de dados públicos, em especial quanto ao melhor tratamento dos daos e validação de negócios, ie que seriam para enriquecer a base de dados do BanVic. A contribuição do colega é válida e carrega em si potenciais melhorias ao banco.

Em que pese o IPCA (indice de precos ao consumidor amplo) ser um bom termometro da inflacao e economia, ele reflete uma realidade menos acurada,o IPCA , leva em conta mais itens supefluos, logo, dialoga com populacao mais abastada.

O INPC por seu turno trata de itens mais necessarios e de uso comum, ele mede mais fidedignamente os impactos da inflação. O IPCA , por ser mais amplo, acaba diluindo mais as implicacoes de dinâmicas de preços na economia

| Categoria | IPCA | INPC | Diferença |
|---------------------------|--------|--------|-----------|
| Alimentação e bebidas | 21,05% | 23,88% | 2,83% |
| Habitação | 15,93% | 17,88% | 1,95% |
| Artigos de residência | 3,91% | 4,72% | 0,81% |
| Vestuário | 4,36% | 5,10% | 0,74% |
| Transportes | 21,93% | 20,80% | 1,13% |
| Saúde e cuidados pessoais | 12,21% | 10,66% | 1,55% |
| Despesas pessoais | 9,77% | 7,41% | 2,36% |
| Educação | 5,71% | 4,16% | 1,55% |
| Comunicação | 5,12% | 5,38% | 0,26% |

Percebe-se que o interesse seria enriquecer o banco de dados com o fim de melhor ajustar os preços dos créditos e seu risco arrimado em dados que sejam mais aproximados do cenário fático, logo, melhor usar o INPC disponivel por API no site do IBGE.

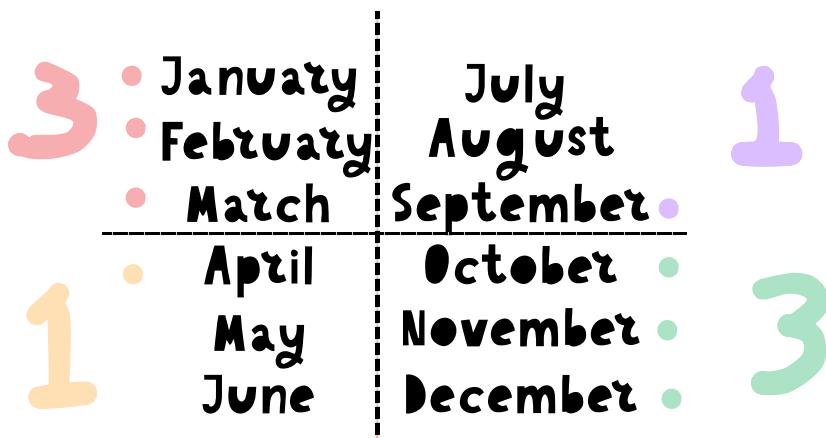
O INPC quando agregado aos algoritmos de *Machine Learning* pode ser usado para fins de predição de cenários futuros, implicando em redução de riscos, melhor aproveitamento de propostas, melhora e adaptação mais ágil aos requisitos de segurança em *churn* de pedidos de crédito. É essencial que seja criado um *pipeline* que possa fazer o scrap dos dados públicos e integrá-los mediante ETL aos data *Warehouse* do BanVic.

Tomo a liberdade de disponibilizar o arquivo das series históricas do INPC no link das análises no github.- <https://github.com/DiegoSVBrito/Projects>-

Respondendo ao próximo questionamento:

Os meses que contém a letra ‘R’ no seu nome e o suposto volume de transações.

A despeito de parecer uma hipótese absurda, podemos responder ao nobre colega usando de referencial estatístico de correlação, ou seja, o quanto um fator influencia em outro.



No caso em específico, quanto o fato de um mês ter a letra ‘R’ ou não afeta no número de negócios. Como apontam os dados o quarto trimestre segue como o *top* em termos de volume de transação. E, por coincidência todos os meses deste trimestre possuem a letra R em seu nome, o que aparenta falsa relação de causalidade.

Fácil debelar a premissa pelo seguinte: o primeiro trimestre também possui ‘R’ em todos os nomes dos meses, contudo, como apontam os dados, fica no *bottom* da análise.

Portanto, trata-se de uma observação que não corresponde à realidade apurada.

Respondendo ao próximo questionamento:

Em relação aos KPI’s - Key Performance Indicators -que podem ser úteis ao tomador de decisões, podemos elencar algumas métricas abaixo:

KPI's Relevantes para Tomadores de Decisão

Métricas essenciais:

- Taxa de aprovação de crédito: Identifica áreas e perfis com maior conversão.
- Volume de transações por agência: Determina quais unidades performam melhor e quais necessitam de ajuste.
- Colaboradores com maior volume de vendas: Indica potenciais lideranças para treinamento e gerenciamento de equipes.
- Gamificação de vendas: Introduzir modelos de incentivo para alavancar a performance dos colaboradores.

Taxa de aprovação de credito - pode indicar melhores oportunidades de vender o produto, seja por critérios de localização, valor da operação, ou mesmo por colaborador. Saber a diferença entre o que gera resultado efetivo para o negócio de crédito significa alocar esforços e recursos obedecendo ao ideal de Pareto, com isso, os números tendem a melhorar drasticamente.

Volume de transações por agência, possível integrar os dados de agencias e de negócios realizados, encontrando qual Unidade vende mais e a partir daí tentar replicar os procedimentos as demais agencias aumentando o aproveitamento

Top 10 Agências com Maior Volume de Transações:

| | nome | cidade | total_transacoes | volume_total |
|---|------------------------|----------------|------------------|--------------|
| 1 | Agência Digital | São Paulo | 33167 | 11579143.34 |
| 4 | Agência Matriz | São Paulo | 8610 | 3549901.76 |
| 9 | Agência Tatuapé | São Paulo | 7156 | 3194382.65 |
| 0 | Agência Campinas | Campinas | 5500 | 1963250.24 |
| 6 | Agência Porto Alegre | Porto Alegre | 4474 | 1605153.92 |
| 5 | Agência Osasco | Osasco | 4697 | 1427088.95 |
| 8 | Agência Rio de Janeiro | Rio de Janeiro | 3779 | 1159050.46 |
| 2 | Agência Florianópolis | Florianópolis | 2133 | 634934.63 |
| 3 | Agência Jardins | São Paulo | 2109 | 479622.44 |
| 7 | Agência Recife | Recife | 374 | 112926.01 |

Os funcionários que vendem mais, ou seja, quais profissionais podem ser os diretores ou gerentes: no propósito de que liderem times e campanhas para melhorar os índices e treinar mais colaboradores.

Também possível implementar modelos de gamificação com o objetivo de melhorar ainda mais a performance dos colaboradores, mediante premiação e valorização de seus esforços num ambiente mais competitivo e desafiador.

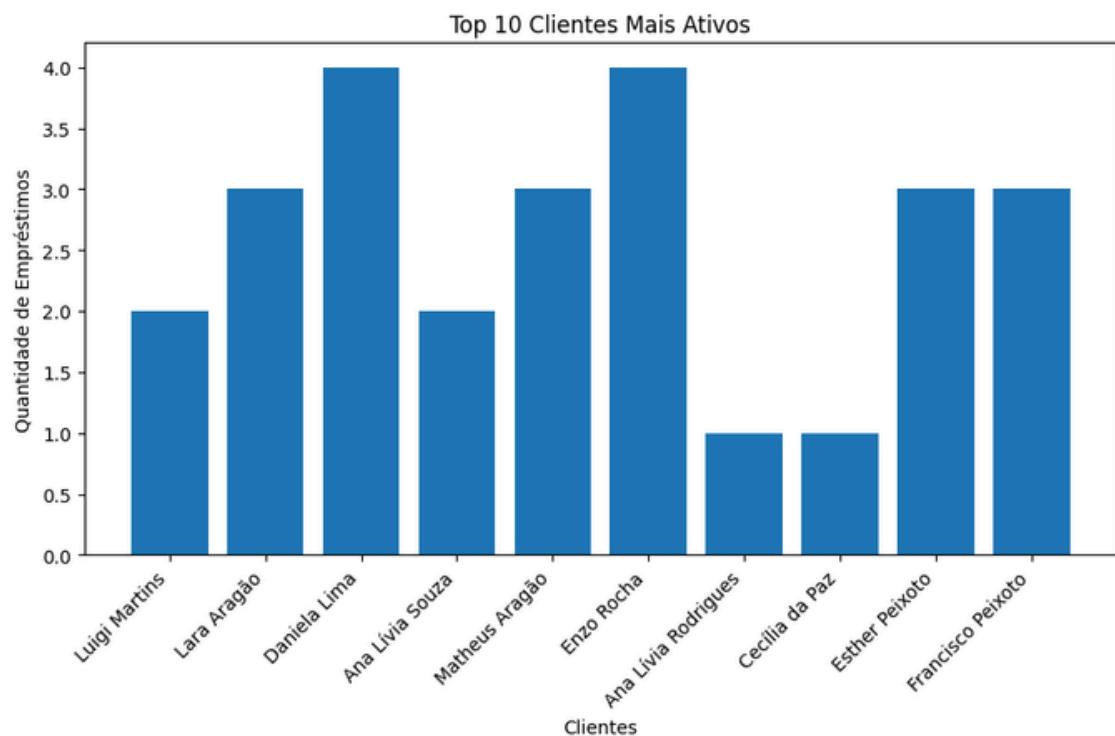
Top 10 Funcionários com Maior Taxa de Aprovação:

| | primeiro_nome | ultimo_nome | nome | taxa_aprovacao |
|----|---------------|-------------|------------------------|----------------|
| 20 | Rafaela | Correia | Agência Porto Alegre | 47.058824 |
| 64 | Sabrina | Silva | Agência Tatuapé | 45.833333 |
| 86 | Luna | Teixeira | Agência Rio de Janeiro | 45.000000 |
| 9 | Vitor Hugo | Novaes | Agência Porto Alegre | 44.444444 |
| 22 | Elisa | Fogaça | Agência Matriz | 43.478261 |
| 81 | Mirella | Sales | Agência Recife | 41.666667 |
| 19 | Alice | Aragão | Agência Digital | 41.176471 |
| 13 | Paulo | Dias | Agência Matriz | 41.176471 |
| 23 | Vitória | Vieira | Agência Matriz | 40.909091 |
| 21 | Davi Luiz | Sales | Agência Tatuapé | 38.888889 |

Volume de transações por clientes, com base na análises é possível encontrar a categoria de clientes, mediante estudo aprofundado e people analytics, e desenvolver algoritmos de previsão para clientes atuais e novos, informando produtos e serviços que sejam de interesse ampliando assim o estímulo e melhorando os resultados em ambiente de soluções financeiras.

- Clientes mais ativos:

| | cod_cliente | quantidade_emprestimos | primeiro_nome | ultimo_nome |
|---|-------------|------------------------|---------------|-------------|
| 0 | | 2 | Luigi | Martins |
| 1 | | 4 | Lara | Aragão |
| 2 | | 5 | Daniela | Lima |
| 3 | | 6 | Ana Lívia | Souza |
| 4 | | 7 | Matheus | Aragão |
| 5 | | 8 | Enzo | Rocha |
| 6 | | 9 | Ana Lívia | Rodrigues |
| 7 | | 10 | Cecília | da Paz |
| 8 | | 11 | Esther | Peixoto |
| 9 | | 15 | Francisco | Peixoto |

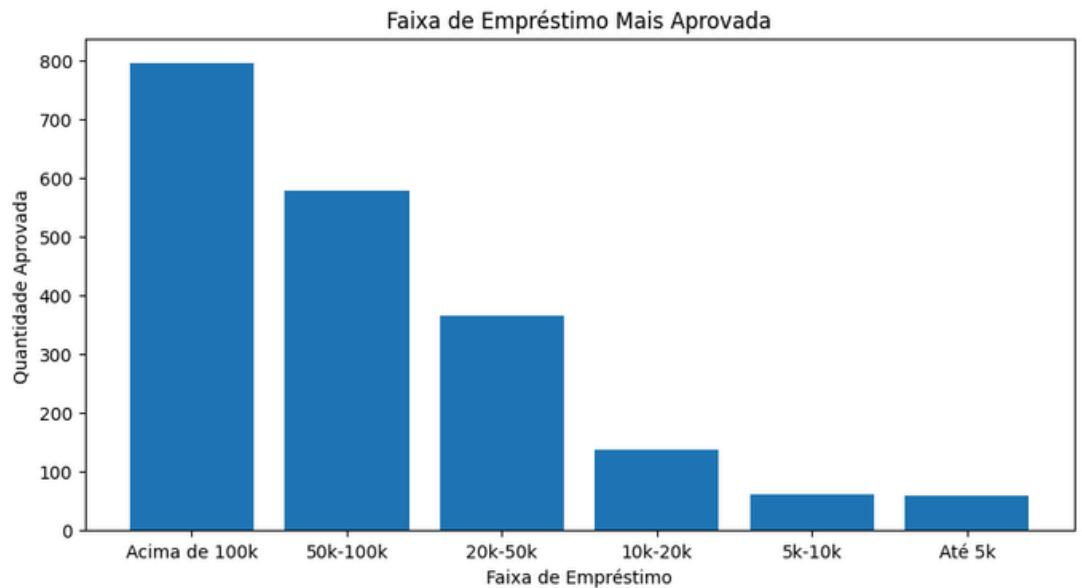


Faixa de crédito mais aprovada - há uma clara correlação entre valor e chance de aprovação, ou seja, o BanVic está com foco em clientes de maior poder aquisitivo, logo, pode expandir seus serviços para clientes de outras classes sociais.

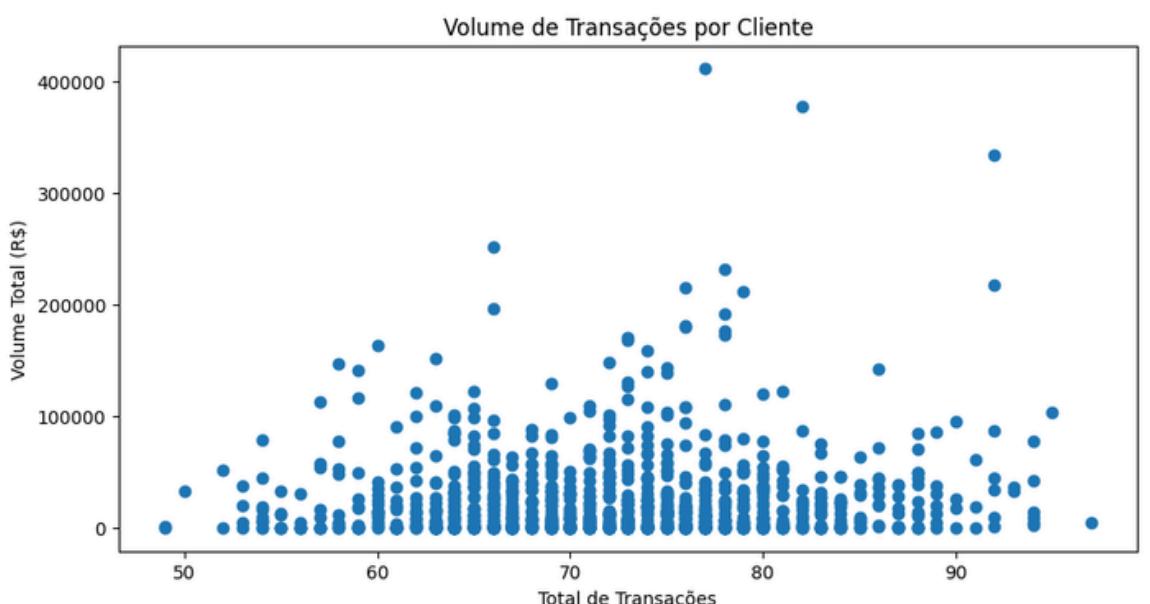
Há uma concentração em créditos acima de 50.000,00 o que gera mal aproveitamento de outras fatias do mercado.

Há espaço de mercado em ofertas de crédito de até R\$10.000,00 .

| | Faixa de empréstimo mais aprovada: | quantidade_aprovada |
|---|------------------------------------|---------------------|
| 0 | Acima de 100k | 797 |
| 1 | 50k-100k | 578 |
| 2 | 20k-50k | 366 |
| 3 | 10k-20k | 138 |
| 4 | 5k-10k | 62 |
| 5 | Até 5k | 59 |



Faixa de Volume de movimentação - há uma clara correlação também entre a atividade de movimento financeiro e os clientes mais ativos em termos de volume de transações. As contas que têm movimentações significativas estão aglutinadas em grupos bem distinos, sendo que as contas de maior volume alcançam até 170 mil reais em transações.



Conclusão:

Nosso time focou as análises em desvendar insights acionáveis que impulsionarão a performance do Banvic a novos patamares.

Nossa investigação revelou oportunidades significativas para otimizar nossos processos de aprovação de crédito e gerenciar de forma proativa a demanda sazonal.

Recomendamos fortemente: uma revisão completa dos critérios de aprovação de crédito, com foco especial no último trimestre, onde identificamos um potencial inexplorado para aumentar nosso market share e receita.

A implementação de sistemas digitais de aprovação automática para empréstimos de menor valor será um diferencial competitivo, agilizando o processo e melhorando a experiência do cliente.

Além disso, é imperativo alinhar nossa estratégia de recursos humanos com as flutuações de demanda ao longo do ano. Através de um planejamento proativo de contratações e treinamentos, podemos garantir que nossas equipes estejam bem dimensionadas e capacitadas para atender aos picos de volume de transações, especialmente no quarto trimestre. Essa abordagem não apenas maximizará nossa eficiência operacional, mas também fortalecerá nosso *employer branding* como uma organização que valoriza e investe em seu capital humano.

No âmbito da gestão de risco, nossa análise identificou o INPC como um indicador econômico mais preciso para nosso público-alvo. Recomendamos fortemente a integração desse índice em nossos modelos de precificação e concessão de crédito. Ao fazê-lo, poderemos tomar decisões mais embasadas, minimizar perdas potenciais e até mesmo explorar técnicas avançadas de machine learning para prever cenários econômicos e ajustar nossas políticas de crédito de forma dinâmica.

Por fim, para engajar e motivar nossos colaboradores, sugerimos a adoção de ferramentas inovadoras de gamificação. Ao criar um ambiente de saudável competição e recompensar a performance excepcional, poderemos impulsionar a produtividade, promover a retenção de talentos e estabelecer o Banvic como um líder em inovação no setor financeiro.

Nossa equipe está à disposição para discutir em detalhes cada ponto levantado e apoiar na elaboração de um plano de ação detalhado para execução imediata.

Agradeço seu apoio contínuo e visão inspiradora. Juntos, levaremos o Banvic a novos patamares de sucesso, impulsionados pelo poder dos dados e da inovação estratégica.
Atenciosamente,

Diego Brito
head da Equipe de Data Analysis do Banvic